

UNIVERSIDADE DE SÃO PAULO
ESCOLA DE ARTES, CIÊNCIAS E HUMANIDADES
PROGRAMA DE PÓS-GRADUAÇÃO EM SISTEMAS DE INFORMAÇÃO

ARTHUR GARCIA TAKAHASHI

Agentes Inteligentes baseados em Large Language Models para apoio à tomada de decisão em sistemas de monitoramento da qualidade da água

São Paulo
2027

ARTHUR GARCIA TAKAHASHI

Agentes Inteligentes baseados em Large Language Models para apoio à tomada de decisão em sistemas de monitoramento da qualidade da água

Orientador: Prof. Dr. Marcelo Lauretto
Coorientador: Prof. Dr. Fábio Nakano

São Paulo
2027

Sumário

1 Introdução 4

2 Fundamentação teórica 5

2.1 Inteligência Artificial 5

2.2 Agentes inteligentes 5

2.3 Large Language Models 8

2.3.1 Retrieval-Augmented Generation 8

2.3.2 Sistemas baseados em agentes 9

2.4 Arquiteturas baseadas em agentes e LLMs 10

2.4.1 Componentes arquiteturais de agentes baseados em LLMs 10

2.4.2 Integração com fontes externas e RAG 12

2.4.3 Arquiteturas multiagentes 12

2.5 Dados de Sensores 13

2.6 Detecção de Anomalias 13

2.7 Considerações Finais 14

3 Revisão Sistemática 15

4 Metodologia 16

5 Resultados experimentais 17

6 Conclusões 18

REFERÊNCIAS 19

APÊNDICES **20**

Apêndice A – Protocolo da revisão do estado da arte 21

A.1 Tema da revisão 21

A.2 Tipo de revisão 21

A.3 Questões de pesquisa 21

A.3.1 QP1 – Aplicações de LLMs no monitoramento da qualidade da água 21
A.3.2 QP2 – Utilização de dados de sensores 22
A.3.3 QP3 – Mecanismos de apoio à decisão 22
A.3.4 QP4 – Limitações e oportunidades de pesquisa 22
A.4 Bases de dados usadas 23
A.5 String de busca 23
A.6 Estratégia de seleção de estudos primários 24
A.6.1 Critérios de inclusão 24
A.6.2 Critérios de exclusão 24
A.7 Critérios de qualidade 25
A.8 Estratégia para extração de dados e síntese de resultados 25

Apêndice B – Resultados da condução da revisão do estado da arte 27
B.1 Relato da condução 27
B.1.1 Dados gerais da execução 27
B.1.2 Registro das consultas e limitações documentais 28
B.1.3 Processo de seleção dos estudos primários 28
B.2 Tabela dos estudos primários selecionados 28
B.3 Análise descritiva 29
B.3.1 Distribuição dos artigos no tempo 29
B.3.2 Tipos de veículos de publicação 29
B.3.3 Distribuição por país, instituição e autores 30

1 Introdução

2 Fundamentação teórica

2.1 Inteligência Artificial

A inteligência Artificial não pode simplesmente ser definida por uma única frente, ela é dividida por Russell e Norvig (2021) em quatro abordagens baseadas em duas dimensões conceituais que são Humano versus Racional e Pensamento versus Comportamento. A partir dessas dimensões, devivam-se as quatro aborgadens: Agir como humanos (Teste de Turing), Pensar como humanos (Modelagem Cognitiva), Pensar racionalmente (Leis de Lógica) e Agir racionalmente (Agentes Racionais). Esta último veio a se tornar o modelo padrão e mais bem-sucedido do que podemos chamar de IA moderna por focar em agir de forma racional com base em conhecimento (RUSSELL; NORVIG, 2021, p. 22).

Uma evolução importante do aprendizado de máquina ocorreu com o desenvolvimento das técnicas de aprendizado profundo (*deep learning*). Essas técnicas utilizam modelos compostos por múltiplas camadas de processamento capazes de aprender representações dos dados em diferentes níveis de abstração. Dessa forma, características relevantes para a realização de uma determinada tarefa podem ser aprendidas diretamente a partir dos dados, reduzindo a necessidade de definir manualmente todas as características que serão utilizadas pelo modelo (LECUN; BENGIO; HINTON, 2015).

O aprendizado profundo apresentou avanços significativos em diferentes domínios, incluindo reconhecimento de fala, reconhecimento e detecção de objetos, processamento de imagens, vídeo e áudio, além de aplicações em descoberta de fármacos e genômica. Estes avanços estão associados, entre outros fatores, à capacidade das redes neurais profundas de aprender representações hierárquicas a partir de grandes conjuntos de dados (LECUN; BENGIO; HINTON, 2015).

2.2 Agentes inteligentes

Para Russell e Norvig (2021) agente é qualquer entidade que percebe seu ambiente por meio de sensores e age sobre ele por meio de atuadores.

O conceito de agente inteligente constitui uma das abordagens utilizadas na Inteligência Artificial para representar sistemas capazes de interagir com um ambiente e realizar ações orientadas a objetivos previamente estabelecidos. Nesse contexto, um agente

pode ser compreendido como uma entidade que recebe informações sobre o ambiente, processa essas informações e seleciona ações a serem tomadas de acordo com os objetivos (MüLLER, 1999).

Müller (MüLLER, 1999) organiza as principais abordagens para arquiteturas de agentes em categorias que incluem arquiteturas reativas, deliberativas e voltadas à interação, além de discutir arquiteturas híbridas que combinam características dessas diferentes abordagens. Essa perspectiva permite compreender os agentes não apenas a partir de suas capacidades individuais, mas também considerando a forma como percebem o ambiente, tomam decisões e interagem com outras entidades.

Além das características arquiteturais, os agentes podem ser classificados considerando sua relação com o ambiente e seu modo de interação. Müller (MüLLER, 1999) apresenta uma classificação que considera, entre outros aspectos, o estado material do agente e seu modo primário de interação. Quanto ao estado material, distinguem-se agentes de hardware, que possuem presença física e interagem com ambientes físicos por meio de sensores e atuadores, e agentes de software, que interagem com ambientes computacionais reais ou virtuais. Quanto ao modo de interação, são considerados agentes autônomos, sistemas multiagentes e agentes assistentes (MüLLER, 1999).

A fim de ilustrar a relação prática dos fundamentos teóricos de agentes descritos por Müller (1999), apresenta-se um mapeamento conceitual em forma de tabela resumida. Como pode ser observado no Quadro 1, os diferentes paradigmas arquiteturais e taxonômicos são relacionados inclusive para ilustrar de forma mais didádica foi adicionado na última coluna, a título de exemplo, um cenário hipotético de monitoramento e supervisão hídrica de alta frequência.

De acordo com Cheng et al. (CHENG *et al.*, 2026), arquiteturas baseadas em LLMs podem incorporar diferentes mecanismos para ampliar as capacidades dos agentes, incluindo planejamento, memória, reflexão e utilização de ferramentas. Esses mecanismos permitem que o agente realize tarefas que envolvem múltiplas etapas, utilizando informações obtidas durante sua interação com o ambiente para orientar ações posteriores. Os autores também discutem sistemas multiagentes baseados em LLMs, nos quais diferentes agentes podem assumir papéis distintos, comunicar-se e coordenar suas ações para a resolução de problemas.

Dessa forma, os agentes inteligentes podem ser entendidos como sistemas cuja característica fundamental não está apenas na execução isolada de uma tarefa, mas

Quadro 1 – Paradigmas de agentes segundo Müller (1999) e sua aplicação no sistema proposto

Categoria	**Classificação**	**Descrição Teórica**	**Aplicação no Monitoramento Hídrico**
Arquitetura de Controle	Reativa	Decisões baseadas em estímulos diretos, sem modelo interno do mundo.	Leitura em tempo real e processamento imediato de alertas básicos.
	Deliberativa	Raciocínio lógico, planejamento e representações internas complexas.	Agente de IA interpretando as anomalias e formulando diagnósticos.
	Híbrida	Combinação de camadas reativas (tempo real) e deliberativas (metas).	Arquitetura central proposta para o monitoramento de alta frequência.
	De Interação	Foco na coordenação, cooperação e comunicação entre agentes.	Orquestração do Sistema Multiagente (SMA) para monitoramento hídrico.
Taxonomia: Estado Material	Hardware	Agentes com presença física, interagindo via sensores físicos.	Sondas multiparamétricas instaladas *in situ* nos rios.
	Software	Agentes virtuais operando em ambientes computacionais ou digitais.	Agentes cognitivos baseados em LLMs e modelos de IA.
Taxonomia: Modo de Interação	Autônomo	Foco na relação direta e independente entre o próprio agente e seu ambiente.	Sonda hídrica coletando e transmitindo dados de forma isolada por telemetria.
	Multiagente	Presença de outros agentes no ambiente, com cooperação e compartilhamento de informações.	Nós e sondas cooperando para analisar a qualidade da água ao longo de toda a bacia.
	Assistente	Projetados para interagir diretamente com humanos e agir em seu benefício.	Interface em linguagem natural (LLM) gerando relatórios claros para o gestor.

Fonte – Adaptado de Müller (1999)

na capacidade de perceber informações, processá-las, selecionar ações e interagir com o ambiente de acordo com objetivos estabelecidos. A evolução das arquiteturas reativas, deliberativas e híbridas para abordagens que incorporam modelos de linguagem, memória, planejamento e utilização de ferramentas estabelece uma ponte entre os fundamentos tradicionais dos agentes inteligentes e as arquiteturas contemporâneas baseadas em LLMs (MüLLER, 1999; CHENG *et al.*, 2026).

2.3 Large Language Models

Os (*Large Language Models* – LLMs), ou Grandes Modelos de Linguagem, representam uma evolução dos modelos de processamento de linguagem natural (PLN) baseada no pré-treinamento auto-supervisionado em grandes volumes de dados textuais. Esses modelos são capazes de aprender representações linguísticas e padrões de relacionamento entre palavras, sentenças e documentos, permitindo sua aplicação em diferentes tarefas de compreensão e geração de linguagem natural. A evolução dos modelos de linguagem está diretamente relacionada ao aumento da escala dos modelos, dos conjuntos de dados utilizados no treinamento e dos recursos computacionais disponíveis (ZHAO *et al.*, 2026).

De acordo com Zhao *et al.* (2026), o ciclo de vida de desenvolvimento de um LLM moderno em quatro dimensões principais: etapas distintas de treinamento: (i) o pré-treinamento, no qual o modelo adquire conhecimento geral de mundo e habilidades linguísticas por meio da predição do próximo token; (ii) o pós-treinamento, que inclui o ajuste fino supervisionado (*SFT*) e o aprendizado por reforço baseado em retroalimentação humana (*RLHF*); (iii) a utilização, que são as estratégias eficazes de implantação e aplicações práticas; e (iv) avaliação, que é a mensuração completa das capacidades e dos riscos. Essa perspectiva evidencia que o desempenho de um modelo não depende exclusivamente de sua arquitetura ou quantidade de parâmetros, mas também das estratégias utilizadas para treiná-lo, adaptá-lo, integrá-lo a outras fontes de informação e avaliar seus resultados (ZHAO *et al.*, 2026).

2.3.1 Retrieval-Augmented Generation

Uma das abordagens utilizadas para reduzir as limitações relacionadas ao conhecimento paramétrico dos LLMs é o *Retrieval-Augmented Generation* (RAG). A abordagem combina um modelo de linguagem com mecanismos externos de recuperação de informação, permitindo que o modelo utilize documentos ou outras fontes de conhecimento durante a geração da resposta (LEWIS *et al.*, 2020).

Em uma arquitetura RAG, o processo pode ser dividido, de forma geral, em três etapas. Na primeira etapa, denominada recuperação (*retrieval*), são identificados documentos ou trechos de documentos relevantes para a consulta realizada pelo usuário.

Essa recuperação pode utilizar métodos baseados em correspondência lexical ou métodos semânticos fundamentados em representações vetoriais. Na segunda etapa, as informações recuperadas são incorporadas ao contexto fornecido ao modelo de linguagem, juntamente com as instruções necessárias para a realização da tarefa. Finalmente, na terceira etapa, o LLM utiliza esse contexto enriquecido para gerar a resposta (ZHAO *et al.*, 2026).

Entretanto, a qualidade de um sistema RAG depende diretamente da qualidade das informações recuperadas. Documentos irrelevantes, incompletos ou contraditórios podem ser incorporados ao contexto e influenciar negativamente a resposta gerada. Por esse motivo, estratégias como reranking, expansão ou reescrita de consultas, filtragem de documentos e recuperação iterativa podem ser empregadas para aumentar a relevância do contexto disponibilizado ao LLM (ZHAO *et al.*, 2026).

2.3.2 Sistemas baseados em agentes

Uma evolução adicional na utilização dos LLMs consiste na construção de sistemas baseados em agentes (*agentic systems*). Nessa abordagem, o modelo de linguagem deixa de atuar apenas como um mecanismo de entrada e saída textual e passa a desempenhar o papel de componente central de raciocínio em um sistema capaz de perceber informações, planejar ações, utilizar ferramentas e interagir com um ambiente (ZHAO *et al.*, 2026).

Sistemas agentic podem ser estruturados a partir de três componentes funcionais principais: memória, planejamento e execução. A memória permite armazenar informações relacionadas às interações anteriores e ao contexto da tarefa. O planejamento possibilita decompor objetivos complexos em uma sequência de subtarefas e revisar estratégias de acordo com os resultados obtidos. A execução é responsável pela realização das ações planejadas, podendo envolver a utilização de ferramentas externas, APIs, mecanismos de busca, bancos de dados ou interpretadores de código (ZHAO *et al.*, 2026).

O funcionamento desses sistemas ocorre de maneira iterativa. Inicialmente, o agente observa o estado atual da tarefa e recupera informações relevantes de sua memória. Em seguida, o componente de planejamento determina uma ação ou sequência de ações. Essas ações são executadas e os resultados obtidos são utilizados como novo contexto para o próximo ciclo de decisão. Dessa forma, o sistema estabelece um ciclo contínuo de percepção, planejamento, execução e avaliação (ZHAO *et al.*, 2026).

Essa evolução, contudo, também introduz novos desafios. Sistemas agentic precisam lidar com crescimento do contexto, gerenciamento de memória, erros acumulados durante a execução, resultados inesperados de ferramentas e necessidade de verificar as ações realizadas. Assim, a confiabilidade desses sistemas depende não apenas das capacidades do LLM, mas também da arquitetura responsável pelo gerenciamento de memória, planejamento, execução e avaliação das ações (ZHAO *et al.*, 2026).

De início, os LLMs foram utilizados como modelos capazes de compreender e gerar linguagem, depois, mecanismos como o RAG permitiram complementar com fontes externas e só então as arquiteturas agênticas permitiram combinar os modelos com memória, planejamento e ferramentas para a execução de tarefas mais complexas.

2.4 Arquiteturas baseadas em agentes e LLMs

Os sistemas baseados em agentes constituem uma abordagem consolidada na Ciência da Computação para a construção de software capaz de perceber informações do ambiente, tomar decisões e executar ações orientadas a objetivos (MüLLER, 1999).

Do ponto de vista arquitetural, um agente baseado em LLM pode ser compreendido como um sistema composto por um núcleo de raciocínio associado a mecanismos externos que ampliam as capacidades do modelo. O LLM fornece a capacidade de interpretar instruções, organizar informações, realizar inferências e selecionar ações, enquanto componentes auxiliares permitem manter informações contextuais, consultar fontes externas e interagir com ferramentas ou ambientes. Essa composição permite que o agente ultrapasse algumas das limitações inerentes ao conhecimento paramétrico do modelo e execute tarefas que exigem múltiplas etapas de interação (CHENG *et al.*, 2026; ZHAO *et al.*, 2026).

2.4.1 Componentes arquiteturais de agentes baseados em LLMs

As arquiteturas contemporâneas de agentes baseados em LLMs podem ser organizadas em torno de diferentes componentes funcionais. Embora existam variações significativas entre as propostas, três elementos fundamentais podem ser destacados: memória, planejamento e execução. Esses componentes são integrados ao modelo de linguagem em um processo iterativo no qual informações do ambiente são analisadas, ações são planejadas e

executadas e os resultados obtidos são utilizados para orientar as etapas seguintes (CHENG *et al.*, 2026; ZHAO *et al.*, 2026).

A memória é responsável por armazenar informações relevantes para a continuidade da interação e para a execução de tarefas que ultrapassam uma única chamada ao modelo. Em termos gerais, pode-se distinguir entre memória de curto prazo e memória de longo prazo. A primeira está associada às informações presentes no contexto corrente do modelo, incluindo instruções, observações e resultados intermediários. A segunda envolve mecanismos externos capazes de persistir informações entre diferentes etapas ou interações, possibilitando sua recuperação quando necessário (ZHAO *et al.*, 2026).

O planejamento constitui outro componente fundamental. Enquanto o modelo de linguagem pode produzir uma resposta diretamente a partir de uma solicitação, um agente precisa frequentemente decompor um objetivo complexo em uma sequência de subtarefas. O planejamento permite determinar quais ações devem ser realizadas, em que ordem e quais informações ou ferramentas são necessárias para alcançar o objetivo. Em arquiteturas baseadas em LLMs, esse processo pode ocorrer de maneira iterativa, permitindo que o agente revise seu plano a partir das informações obtidas durante a execução (CHENG *et al.*, 2026; ZHAO *et al.*, 2026).

A execução, por sua vez, corresponde à realização das ações definidas durante o planejamento. Em arquiteturas mais simples, o próprio LLM pode produzir uma ação ou instrução textual. Em arquiteturas mais sofisticadas, o agente pode utilizar ferramentas externas, como mecanismos de busca, APIs, bancos de dados, interpretadores de código e outros serviços computacionais. Essa capacidade de utilização de ferramentas amplia o espaço de ações disponível ao agente e permite que ele acesse informações ou execute operações que não poderiam ser realizadas exclusivamente a partir do conhecimento armazenado nos parâmetros do modelo (ZHAO *et al.*, 2026).

A interação entre esses componentes pode ser representada por um ciclo contínuo. Inicialmente, o agente recebe uma tarefa e observa o estado atual do ambiente. Em seguida, recupera informações relevantes de sua memória, interpreta o contexto e estabelece um plano de ação. As ações planejadas são então executadas, podendo envolver tanto o próprio modelo quanto ferramentas externas. Os resultados dessas ações retornam ao agente na forma de novas observações, que podem ser utilizadas para atualizar o contexto e a memória e, posteriormente, revisar ou gerar novas ações. Dessa forma, a arquitetura deixa de representar um fluxo linear de entrada e saída e passa a operar como um ciclo de

percepção, raciocínio, ação e feedback (MüLLER, 1999; CHENG *et al.*, 2026; ZHAO *et al.*, 2026).

2.4.2 Integração com fontes externas e RAG

A utilização de fontes externas constitui um mecanismo importante para ampliar a capacidade dos agentes baseados em LLMs. Embora modelos de linguagem possuam grande quantidade de conhecimento incorporado em seus parâmetros, esse conhecimento pode ser limitado em relação a informações específicas de domínio, conteúdos privados ou informações que sofrem alterações frequentes. A abordagem de *Retrieval-Augmented Generation* (RAG) foi proposta como uma forma de combinar a capacidade generativa do modelo com informações recuperadas de fontes externas (LEWIS *et al.*, 2020).

Em uma arquitetura RAG, documentos ou registros relevantes são inicialmente recuperados a partir de uma consulta. As informações selecionadas são então incorporadas ao contexto fornecido ao modelo, que utiliza esse conhecimento adicional durante a geração da resposta (LEWIS *et al.*, 2020). Em agentes baseados em LLMs, esse mecanismo pode ser integrado como um componente arquitetural de recuperação de conhecimento, permitindo que o agente consulte bases documentais, bancos de dados ou outras fontes externas durante a execução de suas tarefas (ZHAO *et al.*, 2026).

A integração entre agentes e RAG é particularmente relevante quando o sistema precisa operar sobre conhecimento especializado ou informações que não fazem parte do conhecimento paramétrico do modelo. Nesse cenário, o agente pode identificar a necessidade de informações adicionais, formular ou reformular uma consulta, recuperar os conteúdos relevantes e incorporá-los ao processo de raciocínio. O mecanismo de recuperação passa, portanto, a fazer parte do ciclo de decisão do agente, em vez de constituir apenas uma etapa independente de geração de respostas (LEWIS *et al.*, 2020; ZHAO *et al.*, 2026).

2.4.3 Arquiteturas multiagentes

Em arquiteturas multiagentes, a coordenação pode ocorrer de maneira centralizada ou distribuída. No primeiro caso, um agente ou componente coordenador é responsável por decompor a tarefa, distribuir responsabilidades e organizar os resultados produzidos pelos

demais agentes. No segundo, os próprios agentes podem interagir entre si, compartilhando informações e tomando decisões de maneira mais descentralizada. Essas diferentes formas de organização permitem explorar especialização funcional, paralelização de tarefas e mecanismos de colaboração entre agentes (CHENG *et al.*, 2026; ZHAO *et al.*, 2026).

A arquitetura multiagente introduz, entretanto, novos desafios relacionados à coordenação, comunicação e consistência das decisões. À medida que o número de agentes aumenta, torna-se necessário controlar a troca de informações, evitar redundância de tarefas e determinar mecanismos para resolução de conflitos. Assim, a utilização de múltiplos agentes não representa apenas a replicação de um mesmo componente, mas exige mecanismos arquiteturais específicos para orquestração e colaboração (CHENG *et al.*, 2026).

2.5 Dados de Sensores

No domínio dos recursos hídricos, a transição do monitoramento manual convencional para sistemas automatizados de alta frequência revolucionou a governança ambiental (LEIGH *et al.*, 2019). Sensores multiparamétricos modernos realizam leituras semi-contínuas de variáveis como turbidez (expressa em NTU) e condutividade elétrica calibrada a 25 °C (expressa em μS/cm), registrando dados de forma automática em intervalos temporais curtos, tipicamente de hora em hora ou de acordo com a variação do nível do leito do rio (LEIGH *et al.*, 2019). Essas variáveis atuam frequentemente como substitutos (*surrogates*) em tempo real para a estimativa de poluentes de análise química complexa e demorada, tais como sedimentos suspensos totais e concentrações de fósforo e nitrato (LEIGH *et al.*, 2019).

2.6 Detecção de Anomalias

No contexto de sensores físico-químicos em redes hídricas, as anomalias decorrem majoritariamente de falhas técnicas instrumentais, tais como esgotamento de baterias, calibração inadequada, falhas de transmissão de dados e, especialmente, a bioincrustação (*biofouling*) das sondas submersas, as quais podem mascarar ou distorcer os padrões ecológicos reais (LEIGH *et al.*, 2019).

No domínio dos sistemas inteligentes de monitoramento hídrico e Internet das Coisas (IoT), a necessidade de processamento contínuo em tempo real de grandes volumes de dados de sensores (*data streams*) impulsionou a adoção de paradigmas de Processamento de Eventos Complexos (CEP – *Complex Event Processing*) integrados a algoritmos eficientes de aprendizado de máquina (SUN *et al.*, 2019). Conforme demonstrado por Sun *et al.* (2019), motores de CEP de alto desempenho (como o Apache Kafka) integrados a bancos de dados de séries temporais (como o InfluxDB) viabilizam a ingestão e o processamento de dados contínuos com baixíssima latência.

Desafios práticos da detecção de anomalias em geociências e monitoramento ambiental envolvem lidar com o severo desbalanceamento de classes e a alta sazonalidade dos ecossistemas (LEIGH *et al.*, 2019; SUN *et al.*, 2019). O principal desafio analítico reside na diferenciação precisa entre anomalias técnicas instrumentais e variações ecológicas extremas legítimas do próprio corpo d'água (como picos de turbidez devidos a enxurradas sazonais decorrentes de precipitação intensa), o que demanda a incorporação de conhecimento de domínio e a combinação híbrida de múltiplos métodos de detecção de forma modular e adaptável (LEIGH *et al.*, 2019; SUN *et al.*, 2019).

2.7 Considerações Finais

A trajetória percorrida partiu dos fundamentos de Inteligência Artificial e arquiteturas de agentes inteligentes (MüLLER, 1999; RUSSELL; NORVIG, 2021), evoluindo para o uso de Grandes Modelos de Linguagem (*Large Language Models* – LLMs) como núcleos cognitivos de raciocínio e deliberação (CHENG *et al.*, 2026; ZHAO *et al.*, 2026). Para mitigar as limitações de conhecimento paramétrico e alucinações dos LLMs, articulou-se a integração com a arquitetura de Geração Aumentada por Recuperação (RAG) (LEWIS *et al.*, 2020) e com ferramentas analíticas externas, como os algoritmos de detecção de anomalias em séries temporais de sensores hídricos (LEIGH *et al.*, 2019; SUN *et al.*, 2019).

3 Revisão Sistemática

4 Metodologia

5 Resultados experimentais

6 Conclusões

Referências

CHENG, Y.; ZHANG, C.; ZHANG, Z.; MENG, X.; HONG, S.; LI, W.; WANG, Z.; WANG, Z.; YIN, F.; ZHAO, J.; HE, X. Exploring large language model-based intelligent agents: Definitions, methods, and prospects. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, 2026. Citado 7 vezes nas páginas 6, 7, 10, 11, 12, 13 e 14.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. *Nature*, v. 521, n. 7553, p. 436–444, 2015. Citado na página 5.

LEIGH, C.; ALSIBAI, O.; HYNDMAN, R. J.; KANDANAARACHCHI, S.; KING, O. C.; MCGREE, J. M.; NEELAMRAJU, C.; STRAUSS, J.; TALAGALA, P. D.; TURNER, R. D. R.; MENGERSEN, K.; PETERSON, E. E. A framework for automated anomaly detection in high frequency water-quality data from in situ sensors. *Science of The Total Environment*, Elsevier, v. 664, p. 885–898, 2019. Citado 2 vezes nas páginas 13 e 14.

LEWIS, P.; PEREZ, E.; PIKTUS, A.; PETRONI, F.; KARPUKHIN, V.; GOYAL, N.; KUTTLER, H.; LEWIS, M.; YIH, W.-t.; ROCKTASCHEL, T.; RIEDEL, S.; KIELA, D. Retrieval-augmented generation for knowledge-intensive nlp tasks. In: *Advances in Neural Information Processing Systems*. [S.l.: s.n.], 2020. v. 33. Citado 3 vezes nas páginas 8, 12 e 14.

MüLLER, J. P. Architectures and applications of intelligent agents: A survey. *The Knowledge Engineering Review*, v. 13, n. 4, p. 353–380, 1999. Citado 5 vezes nas páginas 6, 7, 10, 12 e 14.

RUSSELL, S. J.; NORVIG, P. *Artificial Intelligence: A Modern Approach*. 4. ed. Hoboken: Pearson, 2021. Citado 2 vezes nas páginas 5 e 14.

SUN, A. Y.; ZHONG, Z.; JEONG, H.; YANG, Q. Building complex event processing capability for intelligent environmental monitoring. *Environmental Modelling & Software*, Elsevier, v. 116, p. 1–6, 2019. Citado na página 14.

ZHAO, W. X.; ZHOU, K.; LI, J.; TANG, T.; WANG, X.; HOU, Y.; MIN, Y.; ZHANG, B.; ZHANG, J.; DONG, Z.; DU, Y.; CHEN, Y.; CHEN, Y.; CHEN, Z.; JIANG, J.; REN, R.; LI, Y.; TANG, X.; LIU, Z.; LIU, P.; NIE, J.-Y.; WEN, J.-R. A survey of large language models. *Frontiers of Computer Science*, v. 20, n. 12, p. 2012627, 2026. Citado 7 vezes nas páginas 8, 9, 10, 11, 12, 13 e 14.

Apêndices

Apêndice A – Protocolo da revisão do estado da arte

A.1 Tema da revisão

A revisão tem como tema a relação entre monitoramento da qualidade da água, sistemas de apoio à decisão, dados de sensores e modelos de linguagem de grande porte (*Large Language Models* – LLMs). O objetivo geral é identificar e analisar estudos científicos que abordem esses temas de forma relacionada, buscando compreender as abordagens utilizadas para analisar e interpretar dados e produzir informações relevantes para o apoio à tomada de decisão no contexto do monitoramento da qualidade da água.

A revisão também busca identificar as principais aplicações, abordagens metodológicas, limitações e oportunidades de pesquisa relacionadas à utilização de modelos de linguagem nesse contexto.

A.2 Tipo de revisão

Esta pesquisa utiliza uma revisão da literatura com buscas estruturadas em bases de dados científicas, critérios de seleção de estudos e procedimentos de extração e síntese das informações.

A classificação metodológica definitiva do tipo de revisão deverá ser fundamentada em referências especializadas sobre revisões da literatura. O protocolo documenta o tema investigado, as questões de pesquisa, as fontes consultadas, a estratégia de busca e os procedimentos de seleção e análise dos estudos.

O processo de condução será documentado no Apêndice B, permitindo distinguir as decisões metodológicas da revisão dos resultados efetivamente obtidos durante as buscas e a seleção das publicações.

A.3 Questões de pesquisa

A.3.1 QP1 – Aplicações de LLMs no monitoramento da qualidade da água

Motivação/justificativa: compreender como os modelos de linguagem de grande porte têm sido utilizados em estudos relacionados ao monitoramento da qualidade da água.

Objetivo: identificar as aplicações, tarefas e objetivos descritos nos estudos que relacionam LLMs e monitoramento da qualidade da água.

Estratégia para resposta: classificar os estudos conforme o domínio de aplicação, a finalidade da solução proposta e o papel desempenhado pelos modelos de linguagem.

A.3.2 QP2 – Utilização de dados de sensores

Motivação/justificativa: compreender como os dados provenientes de sensores são empregados nas soluções investigadas e como são processados para gerar informações relevantes.

Objetivo: identificar os tipos de dados, os parâmetros monitorados e as formas de processamento, análise e interpretação utilizadas.

Estratégia para resposta: extrair informações sobre as fontes de dados, os parâmetros monitorados, os métodos de análise e os resultados produzidos pelas soluções descritas nos estudos.

A.3.3 QP3 – Mecanismos de apoio à decisão

Motivação/justificativa: investigar como as soluções identificadas transformam dados em informações que possam contribuir para a tomada de decisão.

Objetivo: caracterizar os mecanismos de apoio à decisão presentes nos estudos, considerando a geração de alertas, recomendações, explicações e outras informações destinadas aos usuários.

Estratégia para resposta: identificar as saídas produzidas pelas soluções, sua finalidade, a forma de apresentação das informações e a participação do usuário no processo decisório, quando esses aspectos forem descritos.

A.3.4 QP4 – Limitações e oportunidades de pesquisa

Motivação/justificativa: identificar desafios e limitações ainda presentes nas abordagens investigadas, bem como oportunidades para novas pesquisas.

Objetivo: sintetizar as limitações técnicas e metodológicas relatadas nos estudos e identificar lacunas relevantes para o tema da pesquisa.

Estratégia para resposta: extrair e comparar as limitações, os métodos de avaliação, as ameaças à validade e as recomendações para trabalhos futuros apresentadas pelos autores.

A.4 Bases de dados usadas

Foram consultadas cinco bases de dados científicas:

- Scopus;
- Web of Science;
- ScienceDirect;
- IEEE Xplore;
- ACM Digital Library.

As bases foram selecionadas para recuperar publicações relacionadas ao tema da revisão em diferentes áreas, incluindo computação, engenharia e pesquisas sobre monitoramento e análise de dados.

A.5 String de busca

A estratégia de busca foi definida a partir de quatro expressões relacionadas ao tema investigado: monitoramento da qualidade da água, apoio à decisão, dados de sensores e modelos de linguagem de grande porte. As expressões foram combinadas pelo operador booleano *AND*, de modo a buscar estudos que relacionassem os quatro conceitos.

A string utilizada na maior parte das plataformas foi:

```
"water quality monitoring" AND "decision support"
AND "sensor data" AND "large language models"
```

As buscas foram realizadas no período de 4 de agosto de 2026 a 11 de outubro de 2026. Não foi utilizado o termo de exclusão *medical* na estratégia de busca.

A data exata de execução de cada consulta não foi preservada no registro disponível para esta versão do trabalho. Por esse motivo, documenta-se o período geral conhecido, sem atribuir datas específicas a cada base de dados.

Embora a string principal tenha sido utilizada na maior parte das plataformas, eventuais adaptações de sintaxe ou de campos de busca devem ser consideradas conforme os recursos de cada mecanismo. A documentação disponível nesta versão não permite reconstruir integralmente todas as particularidades de cada consulta.

A.6 Estratégia de seleção de estudos primários

A seleção dos estudos considera a relação das publicações com o tema e com as questões de pesquisa. O processo de seleção compreende a identificação dos registros, a verificação de duplicatas, a análise de títulos e resumos e a avaliação do texto completo dos estudos potencialmente relevantes.

As decisões de inclusão e exclusão devem ser registradas durante a condução da revisão, de modo que seja possível documentar os motivos de exclusão e a quantidade de estudos que avançou em cada etapa.

A.6.1 Critérios de inclusão

- Estudos relacionados ao monitoramento da qualidade da água;
- Estudos que abordem dados de sensores em contexto pertinente às questões de pesquisa;
- Estudos que investiguem LLMs, análise de dados ou mecanismos de apoio à decisão relacionados ao escopo da revisão;
- Publicações científicas com informações suficientes para avaliar sua pertinência ao tema e às questões de pesquisa.

A.6.2 Critérios de exclusão

- Registros duplicados entre as bases consultadas;
- Estudos sem relação direta com o tema ou com as questões de pesquisa;
- Estudos que mencionem os termos pesquisados, mas não apresentem conteúdo pertinente ao escopo da revisão;

- Publicações sem informações suficientes para avaliar sua contribuição para as questões de pesquisa;
- Publicações cujo texto completo não possa ser obtido, caso essa condição seja confirmada como critério de exclusão durante a aplicação do protocolo.

Os critérios deverão ser aplicados de maneira consistente ao longo do processo de seleção. A quantidade de registros excluídos e os motivos correspondentes serão documentados no Apêndice B.

A.7 Critérios de qualidade

A aplicação de uma avaliação formal da qualidade metodológica dos estudos não foi especificada nesta versão do protocolo. Caso seja adotada, deverão ser documentados os critérios utilizados, a forma de avaliação e sua influência na seleção e na interpretação dos resultados.

A.8 Estratégia para extração de dados e síntese de resultados

Para cada estudo selecionado, serão extraídas, quando disponíveis, as seguintes informações:

- título, autores, ano e veículo de publicação;
- objetivo e domínio de aplicação;
- problema investigado e contexto de utilização;
- tipos e fontes dos dados utilizados;
- parâmetros de sensores e características dos dados, quando aplicável;
- métodos de processamento, análise e interpretação;
- papel desempenhado pelos LLMs;
- mecanismos de apoio à decisão;
- métodos de avaliação e principais resultados;
- limitações relatadas e oportunidades de pesquisa.

As informações extraídas serão organizadas em uma planilha para facilitar a comparação entre os estudos. A síntese dos resultados combinará análise descritiva das publicações e análise qualitativa do conteúdo, considerando as questões de pesquisa.

A análise buscará identificar tendências, categorias de aplicação, abordagens recorrentes, limitações e lacunas de pesquisa relacionadas ao uso de LLMs, dados de sensores e sistemas de apoio à decisão no monitoramento da qualidade da água.

Apêndice B – Resultados da condução da revisão do estado da arte

B.1 Relato da condução

B.1.1 Dados gerais da execução

As buscas foram realizadas em cinco bases de dados científicas no período de 4 de agosto de 2026 a 11 de outubro de 2026. A estratégia utilizou termos relacionados ao monitoramento da qualidade da água, apoio à decisão, dados de sensores e modelos de linguagem de grande porte.

A string utilizada na maior parte das plataformas foi:

```
"water quality monitoring" AND "decision support"
AND "sensor data" AND "large language models"
```

Não foi utilizado o termo de exclusão *medical*. A data exata de execução de cada consulta não foi preservada no registro disponível; portanto, informa-se apenas o período geral conhecido.

A Tabela 1 apresenta a quantidade de registros informada para cada base de dados.

Tabela 1 – Registros retornados pelas bases de dados

Base de dados	**Registros**
Scopus	15
Web of Science	22
ScienceDirect	22
IEEE Xplore	2
ACM Digital Library	1
Total bruto	**62**

A soma dos resultados informados pelas cinco bases totalizou 62 registros brutos. Esse total representa a quantidade de resultados retornados antes da consolidação e da remoção de duplicatas. Assim, não corresponde necessariamente à quantidade de estudos únicos.

B.1.2 Registro das consultas e limitações documentais

As buscas foram conduzidas ao longo do período informado, mas não há registro disponível da data exata de cada consulta. Por esse motivo, não é possível associar uma data individual a cada base sem introduzir uma informação não documentada.

A string principal foi utilizada na maior parte das plataformas. As adaptações específicas de sintaxe, os campos pesquisados e os filtros próprios de cada mecanismo não estão integralmente documentados nesta versão. Essa limitação deverá ser considerada na avaliação da reprodutibilidade do processo de busca.

Os endereços das plataformas foram utilizados para consultar os resultados. Entretanto, os endereços disponíveis para IEEE Xplore e ACM Digital Library correspondem às páginas gerais das plataformas, não constituindo, isoladamente, evidência persistente da consulta específica realizada.

B.1.3 Processo de seleção dos estudos primários

Os 62 registros identificados constituem o conjunto inicial de resultados da revisão. A partir desse conjunto, devem ser realizadas a consolidação dos registros, a identificação de duplicatas e a avaliação da elegibilidade das publicações.

Nesta versão, as quantidades de duplicatas, exclusões por título e resumo, textos completos avaliados e estudos incluídos ainda não foram consolidadas. Esses valores não são apresentados como resultados porque dependem da execução e do registro das etapas de seleção.

A Figura 1 representa, de forma provisória, a etapa inicial documentada do processo.

B.2 Tabela dos estudos primários selecionados

A tabela definitiva dos estudos primários deverá ser preenchida após a conclusão da seleção. Como essa etapa ainda não foi consolidada, não são apresentados títulos, autores ou anos como se constituíssem o conjunto final de estudos incluídos.

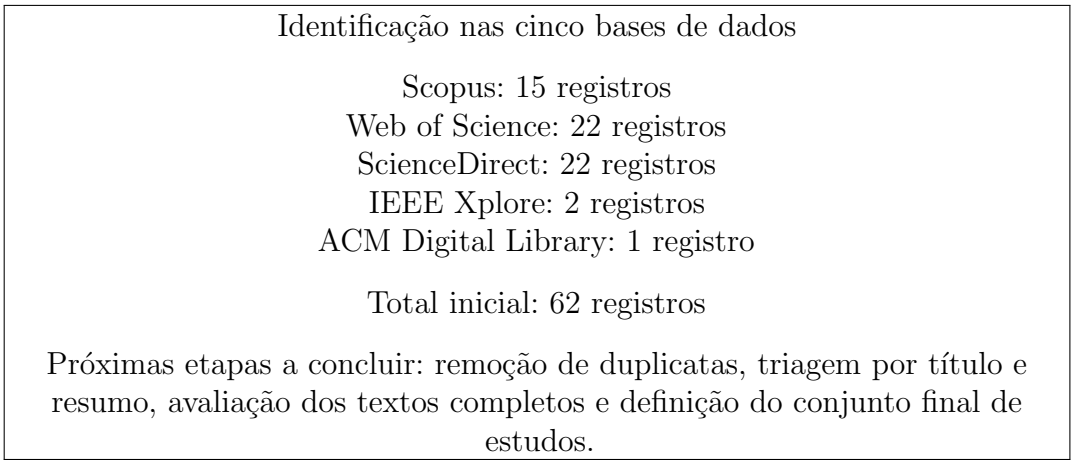


Figura 1 – Etapa inicial documentada do processo de seleção

Após a seleção, a tabela deverá conter, no mínimo, o título da publicação, os autores e o ano de publicação. Recomenda-se também registrar a base de origem e um identificador persistente, quando disponível.

B.3 Análise descritiva

A análise descritiva será realizada sobre o conjunto final de estudos selecionados. Como a seleção ainda não foi concluída, não são apresentados gráficos de distribuição temporal, veículos de publicação, países, instituições ou autores, pois tais análises exigem dados bibliográficos consolidados.

B.3.1 Distribuição dos artigos no tempo

Após a seleção dos estudos primários, será elaborado um gráfico com a quantidade de publicações por ano. A análise buscará identificar a evolução temporal das pesquisas relacionadas ao tema da revisão.

B.3.2 Tipos de veículos de publicação

Os estudos selecionados serão classificados de acordo com o tipo de veículo de publicação, como periódicos científicos e conferências. A distribuição será apresentada em gráfico e acompanhada de uma interpretação dos resultados.

B.3.3 Distribuição por país, instituição e autores

Serão analisadas as informações bibliográficas relativas aos países, às instituições e aos autores dos estudos selecionados. Os resultados serão apresentados por meio de gráficos ou tabelas adequados à distribuição observada, com o objetivo de identificar concentrações de publicações e padrões de colaboração.